

ÉquiAlgo : un financement étudiant équitable

Hackathon Génie et Informatique 2026. Défi de 24 heures. | Cahier des participant·es

HxBuddy affiche uniquement un indicateur F1 et accuracy pour ce défi. Il ne calcule pas les 35 points de la grille officielle ci-dessous. Les livrables finaux et cette grille sont évalués par IVADO.

Une institution financière québécoise évalue les demandes de bourses d'excellence et de prêts d'études avec un modèle d'apprentissage automatique. Il atteint 88 % d'exactitude. Un audit interne a constaté qu'il accorde une bourse à 48,4 % des candidat·es de Montréal et de la Capitale-Nationale, contre 27,3 % au Bas-Saint-Laurent, sur la Côte-Nord et en Gaspésie-Îles-de-la-Madeleine.

La cote R moyenne est de 27,3 dans les régions éloignées et de 28,0 dans les grands centres. Cela explique une partie de l'écart de 21 points. Le reste est inexpliqué.

Votre mandat : diagnostiquer le biais, le corriger, et proposer un plan de surveillance en production.

Toutes les données sont synthétiques. L'institution est fictive.

Installation

```
git clone <URL_DE_VOTRE_DEPOT>
cd defi-equalgo
python3 -m venv venv
source venv/bin/activate      # Windows : venv\Scripts\activate
pip install -r requirements.txt
jupyter notebook baseline_model.ipynb
```

Python 3.10 ou plus récent. Exécutez le carnet une fois avant toute modification. Il entraîne le modèle en production, le mesure et l'audite.

Fichiers

Fichier	Lignes	Contenu
data/donnees_demandes.csv	10 000	demandes historiques, avec decision_octroi
data/candidats_evaluation.csv	4 000	demandes à évaluer, sans étiquette
baseline_model.ipynb		modèle en production, métriques, audit d'équité

Colonnes

Colonne	Signification
id_candidat	identifiant, format C000 000
cote_r_equivalent	performance académique, équivalent cote R, de 15 à 40
programme_etudes	programme d'études, 5 catégories
region_administrative	variable sensible, région administrative du Québec
code_postal_3	trois premiers caractères du code postal
revenu_familial_estime	revenu annuel brut du ménage
heures_travail_semaine	heures travaillées par semaine pendant les études
distance_domicile_campus_km	domicile au campus, en km

Colonne	Signification
<code>premiere_generation_universitaire</code>	1 si première personne de la famille à l'université
<code>decision_octroi</code>	cible, 1 accordé, 0 refusé

Les noms de régions sont écrits sans accents et sans espaces autour du trait d'union : `Montreal`, `Capitale-Nationale`, `Bas-Saint-Laurent`, `Cote-Nord`, `Gaspesie-Iles-de-la-Madeleine`.

Contraintes

Enveloppe fixe. Votre taux d'octroi sur les 4 000 candidat·es d'évaluation doit se situer entre 36 % et 44 %. Hors de cette plage, la section technique vaut zéro.

`decision_octroi` n'est pas la cible. Le jury note contre un étalon de référence construit indépendamment du comité historique. Vous ne l'avez pas. Cette colonne consigne ce que le comité a fait, et c'est le comité qui est audité.

Supprimer `region_administrative` ne fonctionne pas. Retirer cette colonne fait passer l'écart de parité de 0,188 à 0,181. Retirer aussi le code postal l'amène à 0,173. La distance, les heures travaillées, le revenu familial et le code postal portent tous de l'information régionale. La section 5 du carnet le mesure.

Livrables

Un dépôt GitHub, public ou partagé avec les juges, contenant :

- `predictions.csv` à la racine. Deux colonnes, 4 000 lignes plus l'en-tête, valeurs 0 ou 1. La dernière cellule du carnet en écrit un exemple valide.
- `audit_rapport.ipynb`. La mesure du biais, vos métriques d'équité avec leur justification, et les variables proxys que vous avez trouvées.
- `model_corrige.py` ou `.ipynb`. Votre solution d'atténuation, avec un graphique du front de Pareto pour plusieurs réglages de la contrainte.
- `presentation.pdf`. Le support d'un pitch de cinq minutes.

```
id_candidat,decision_octroi
C000 042,1
C000 117,0
```

Notation

Section	Points	Évalué par
Rigueur du diagnostic	25	le jury
Solution technique	35	le correcteur automatique
Gouvernance et éthique	25	le jury
Pitch et qualité du code	15	le jury

Les 35 points automatiques, tous deux mesurés contre l'étalon de référence caché :

- Équité, 20 points. Proportion de l'écart d'égalité des chances du modèle de base qui est refermée. Cet écart de départ vaut 0,270.
- Utilité, 15 points. Concordance avec l'étalon de référence, sur une échelle allant d'un tirage aléatoire respectant l'enveloppe à une répartition parfaite.

Les deux valent zéro si la contrainte d'enveloppe est brisée.

Notes

`fairlearn.postprocessing.ThresholdOptimizer` ajuste les seuils de décision après l'entraînement et s'exécute en quelques secondes. `fairlearn.reductions.ExponentiatedGradient` réentraîne sous contrainte et prend plusieurs minutes.

La parité démographique et l'égalité des chances ne peuvent pas tenir ensemble quand les deux groupes ont des profils différents. Choisissez-en une et préparez-vous à défendre ce choix.

Un modèle unique ne fait pas un front de Pareto. Balayez la contrainte d'équité et tracez les résultats.

Des mentors sont disponibles en tout temps.